



# 数据科学基础 I (Matlab)

— 东北大学 —



数据科学中的数学基础与运算基础



## 函数

- 函数表示量与量之间的关系

$$y = f(x)$$

↑                      ↑  
因变量              自变量

↓



- 标量
- 向量
- 矩阵
- 张量

更广泛的意义：映射，即从 $x$ 所在的“定义域”到 $y$ 所在的“值域”的映射。





## 函数

```
>> x=4
```

```
x =  
4
```

```
>> y=sqrt(x) %sqrt是平方根函数
```

```
y =  
2
```

```
>> z=sin(y) %sin是正弦三角函数
```

```
z =  
0.9093
```

```
>> x=[4 5 6]; y=[1 2 3];
```

```
>> z=dot(x,y) %向量的内积函数
```

```
z =  
32
```



## 向量的长度

○ 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$

○ 则向量长度  $\|x\| = \sqrt{[x, x]} = \sqrt{\sum_{i=1}^n x_i^2}$



向量自身内积





## 向量的范数(norm)

- 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$
- 则有:
  - 该向量的1范数为各个元素的绝对值之和




$$\|x\|_1 = \sum_{i=1}^N |x_i|$$



## 向量的范数(norm)

- 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$
- 则有:
  - 该向量的2范数为各个元素的平方和的平方根


$$\|x\|_2 = \sqrt{\sum_{i=1}^N |x_i|^2}$$





## 向量的范数(norm)

- 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$
- 则有:
  - 该向量的负无穷范数为所有元素的绝对值中最小的



$$\|x\|_{-\infty} = \min |x_i|$$



## 向量的范数(norm)

- 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$
- 则有:
  - 该向量的正无穷范数为所有元素的绝对值中最大的



$$\|x\|_{+\infty} = \max |x_i|$$





## 向量的范数(norm)

- 设向量  $x = [x_1 \ x_2 \ \dots \ x_n]$
- 则有:
  - 该向量的p范数为p次方和的p次方根



$$L_p = \|x\|_p = \sqrt[p]{\sum_{i=1}^N |x_i|^p}$$



## 矩阵范数

- 对任意矩阵 $A_{m \times n}$ , 其元素为 $a_{ij}$ 。
- 矩阵的1-范数（列和范数）：矩阵的每一列上的元素绝对值先求和，再从中取最大值。（列和最大）

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$





## 矩阵范数

- 对任意矩阵 $A_{m \times n}$ , 其元素为 $a_{ij}$ 。
- 矩阵的无穷范数（行范数）：矩阵的每一行上的元素绝对值先求和，再从中取最大值。（行和最大）

$$\|A\|_{\infty} = \max_{1 \leq j \leq m} \sum_{i=1}^n |a_{ij}|$$



## 矩阵范数

- 对任意矩阵 $A_{m \times n}$ , 其元素为 $a_{ij}$ 。
- 矩阵的2-范数（欧几里德范数, 谱范数）：矩阵 $A^T A$ 的最大特征值的平方根。

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$





## 矩阵范数

```
>> A=[-1 0 5; 2 4 6; 0 4 5]
```

A =

-1	0	5
2	4	6
0	4	5



```
>> n=norm(A,1)
```

n =

16

```
>> n=norm(A,2)
```

n =

10.5625

```
>> n=norm(A,inf)
```

n =

12



## 矩阵范数

- 对任意矩阵 $A_{m \times n}$ , 其元素为 $a_{ij}$ 。
- 矩阵的L0范数: 非0元素的个数, 通常用它来表示稀疏, L0范数越小0元素越多, 也就越稀疏。
- 矩阵的L1范数: 矩阵中的每个元素绝对值之和。





## 矩阵范数

- 对任意矩阵 $A_{m \times n}$ , 其元素为 $a_{ij}$ 。
- 矩阵的F范数: 矩阵的各个元素平方之和再开平方根, 它通常也叫做矩阵的L2范数。

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$



## 矩阵的秩

- 指矩阵中所有行向量中极大线性无关组的元素个数

```
>> A=[-1 0 5; 2 4 6; 0 4 5]
```

A =

-1	0	5
2	4	6
0	4	5

```
>> rank(A)
```

ans =  
3

```
>> A=[1 2 3; 2 4 6; 0 4 5]
```

A =

1	2	3
2	4	6
0	4	5

线性  
相关

```
>> rank(A)
```

ans =  
2





## 矩阵的特征向量与特征值

- 设 $A$ 是 $n$ 阶方阵，如果数 $\lambda$ 和 $n$ 维非零列向量 $x$ 使关系式 $Ax=\lambda x$ 成立，那么 $\lambda$ 称为矩阵 $A$ 特征值，非零向量 $x$ 称为 $A$ 的对应于特征值 $\lambda$ 的特征向量。
- 把每个特征向量看做是一个坐标轴，特征值是对应坐标轴（即特征向量）的坐标值。简单来说，就是用特征值（坐标）与特征向量（坐标轴）来表示原矩阵。



## 矩阵的特征向量与特征值

```
>> A = [2 1 0; 1 3 1; 0 1 4]
```

A =

2	1	0
1	3	1
0	1	4

```
>> [V,D] = eig(A)
```

V =

0.7887
-0.5774
0.2113

第一组特征值  
与相应特征向量 ✓

-0.5774
-0.5774
0.5774

第二组特征值  
与相应特征向量 ✓

0.2113
0.5774
0.7887

第三组特征值  
与相应特征向量 ✓

D =

1.2679
0
0

第一组特征值  
与相应特征向量 ✓

0
3.0000
0

第二组特征值  
与相应特征向量 ✓


0
0
4.7321

第三组特征值  
与相应特征向量 ✓






## 特征向量应用：SVD分解




$M$   
 $m \times n$



$U$   
 $m \times m$



$\Sigma$   
 $m \times n$



$V^*$   
 $n \times n$



特征向量矩阵



特征值构成的对角阵



## SVD分解用于图像压缩

原图:

$298 \times 749 = 223202$

取100个特征:

$U: 298 \times 100;$

$S: 100 \times 100;$

$V: 100 \times 749;$

合计: 114700







## SVD分解用于图像压缩

```
a=imread('neu.jpg');  
a = a(:,:,1);  
imshow(mat2gray(a))  
[m, n]=size(a);  
a=double(a);  
r=rank(a);  
[U, S, V]=svd(a);  
k = 100; %取前k个特征  
re=U(:,1:k)*S(1:k,1:k)*V(:,1:k)  
';  
figure;  
imshow(mat2gray(re));
```